

Serigne Bassirou NDIAYE

Data Scientist

Data Scientist avec plus d'un an d'expérience en Machine Learning, NLP et IA générative, je recherche un poste en CDI afin de contribuer au développement de solutions d'intelligence artificielle répondant à des problématiques métiers.

LinkedIn
GitHub

dstndiaye@gmail.com | 07 58 64 47 06 | Île-de-France

Expériences professionnelles

Data Scientist
Caisse des Dépôts (CDC) – Direction de l'innovation et de la prospective (DIP)
De sept. 2025 à sept. 2026 *Paris*

Classification automatique de courriers administratifs
Technologies : Python, Pandas, NumPy, Scikit-learn, TF-IDF, NLP, OCR, Dataiku, SVM, Naive Bayes, Stacking Classifier.

- Préparation et mise à jour des données d'entraînement : nettoyage, filtrage et intégration de nouvelles catégories métier.
- Entraînement et comparaison de modèles de classification, avec une **accuracy de 87 %** sur les jeux de test.
- Livraison de nouveaux modèles adaptés à l'évolution des données et des catégories métier.
- Maintenance et amélioration continue du **pipeline de classification multiclasse** de courriers administratifs basé sur le **NLP** et le **Machine Learning.**
- Migration du pipeline sur **Dataiku** pour faciliter le réentraînement, l'exploitation et le suivi des modèles.

Assistant RAG d'aide à la réponse client – Documentation juridique
Technologies : Python, LangChain, Mistral, FAISS, BGE-M3, LLM, Prompt Engineering.

- Conception d'un système **RAG** destiné à faciliter la recherche d'informations dans une base documentaire interne.
- Structuration de **deux bases de connaissances** : historique de demandes/réponses et documentation métier de référence.
- Mise en place d'une **recherche sémantique** basée sur les embeddings **BGE-M3** et l'indexation vectorielle avec **FAISS.**
- Conception du prompt permettant de générer une réponse contextualisée à partir des documents disponibles.

Analyse d'appels d'offres par IA générative & Prompt Engineering
Technologies : Mistral AI, Large Language Models (LLMs), Prompt Engineering.

- Accompagnement et **acculturation des équipes métier à l'utilisation de l'IA générative**.
- Recueil des besoins métier et conception de prompts adaptés aux cas d'usage d'analyse et de synthèse documentaire.
- Expérimentation et optimisation de différentes stratégies de prompting afin d'améliorer la pertinence et la qualité des réponses générées.
- Analyse comparative des réponses générées afin d'améliorer la cohérence et la qualité des synthèses.
- Animation d'ateliers de formation et partage des bonnes pratiques du **Prompt Engineering.**

Stagiaire Data Scientist
Caisse des Dépôts (CDC) – Direction de l'innovation et de la prospective (DIP)
De juil. 2025 à août 2025 *Paris*

Traitement documentaire, OCR et extraction automatique de données
Technologies : Python, PyMuPDF, OCR, Pandas, Dataiku, Machine Learning, NLP, Tesseract.

- Développement d'une solution de **traitement de formulaires administratifs numérisés** : extraction de texte, détection et correction de l'orientation des pages, puis récupération de données structurées avec **PyMuPDF** et **OCR**.
- Prise en main et analyse d'un **pipeline de classification automatique** de courriers basé sur des techniques de **NLP** et de **Machine Learning**.
- Formation à **Dataiku** et obtention de **6 certifications** autour de la Data Science, du Machine Learning, du **MLOps** et de l'**IA générative.**

Formations

Master Informatique – Machine Learning pour la Science des Données (MLSD)
Université Paris Cité
De 2024 à 2026 *Paris*
Machine Learning, Deep Learning, NLP & Text Mining, IA Générative, LLM, RAG, Séries temporelles, Systèmes de Recommandation, Analyse de graphes, Big Data.

Licence Mathématiques et Applications
Université Paris Cité
De 2022 à 2024 *Paris*
Probabilités, Statistiques, Programmation Orientée Objet (POO / Java), Réseaux et Sécurité informatique.

Licence Mathématiques et Informatique Appliquées
Université Cheikh Anta Diop de Dakar (UCAD)
De 2019 à 2022 *Dakar, Sénégal*
Algèbre, Analyse, Cryptographie , Programmation Orientée Objet, Développement Web, Réseaux.

Compétences

Langages : Python, SQL, R, Java, C
Data Science, Machine & Deep Learning : Pandas, NumPy, Scikit-learn, TensorFlow, Keras, classification supervisée, clustering, SVM, Naive Bayes, Stacking Classifier, analyse de graphes.
IA générative, NLP & RAG : Hugging Face, OpenAI API, Mistral AI, BGE-M3, LangChain, RAG, Prompt Engineering, FAISS, expressions régulières (Regex), spaCy, NLTK.
Outils & méthodes : Dataiku, Git/GitHub, gestion de projet Agile, sprints, tickets, backlog, stand-up meetings

Qualités

Capacité d'adaptation, autonomie, esprit d'équipe, gestion de projet

Langues

Français (Bilingue), **Anglais** (B1) , **Wolof** (Natif)